Datenbanken
VL-1, Einleitung

3MI25-1

Dresden, 10/2026

Dozent: Dr. Harald Pfefferkorn

DHSN
DUALE HOCHSCHULE
SACHSEN

Organisation der Lehrveranstaltung

Historische Entwicklung

Datenbankansatz

Weitere Datenbankmodelle

Aktuelle Entwicklungsrichtungen

Hinweise zur Lehrveranstaltung

Modul: Datenbanken (3IM-DB-IM)

Einführung in die Datenbanktechnologie
- Vom Datei- zum Datenbanksystem
- Anforderungen an die Datenhaltung: Datenunabhängigkeit, Datenintegrität, Datensicherheit
- Aufbau und Organisation von Datenbanksystemen: Lebenszyklus von Datenbanksystemen,
- Datenbankschema, Ausprägung, ANSI-SPARC-Architektur
- Sicherheit in Datenbanksystemen

Datenmodelle und Datenmodellierung
- Datenmodelle, z.B. Relationales Datenmodell, Hierarchisches Datenmodell, Netzwerkdatenmodell
- Der Modellierungsprozess: Entwurfsebenen, Entwurfsphasen
- Das Entity-Relationship-Modell: Grundmodell und Erweiterungen
- Transformation von Entity-Relationship-Modellen in das relationale Schema
- Relationale Algebra
- Abhängigkeiten und Normalformen

Datenbanksprachen SQL
- Überblick über etablierte Datenbanksprachen
- Structured Query Language (SQL) als Industriestandard
- Grundkomponenten: Datendefinition, Datenmanipulation, Datenkontrolle

Einführung NoSQL Datenbanksystem
- Prüfungsleistung: Klausur, der Termin wird im Stunden-/Prüfungsplan bekannt gegeben, keine Hilfsmittel zugelassen

Struktur der Lehrveranstaltung

VL	Inhalt
1	Einführung, Übersicht
2	Historische Datenmodelle
3	Das relationale Modell
4	Datenbankentwurf (1)
5	Datenbankentwurf (2)
6	Relationale Entwurfstechnik / Normalisierung
7	Relationale Anfragesprachen (1)
8	Relationale Anfragesprachen (2)
9	Physische Datenorganisation
10	Transaktionsverwaltung, Fehlerbehandlung
11	Mehrbenutzersynchronisation
12	Verteilte DB und Hauptspeicher DB
13	Objektorientierte DB
14	Internet-Datenbankanbindungen
15	Betriebliche Anwendungen (SAP, OLTP, Data Warehouse, Data Mining)
16	Big Data
17	NoSQL
18	Sicherheitsaspekte

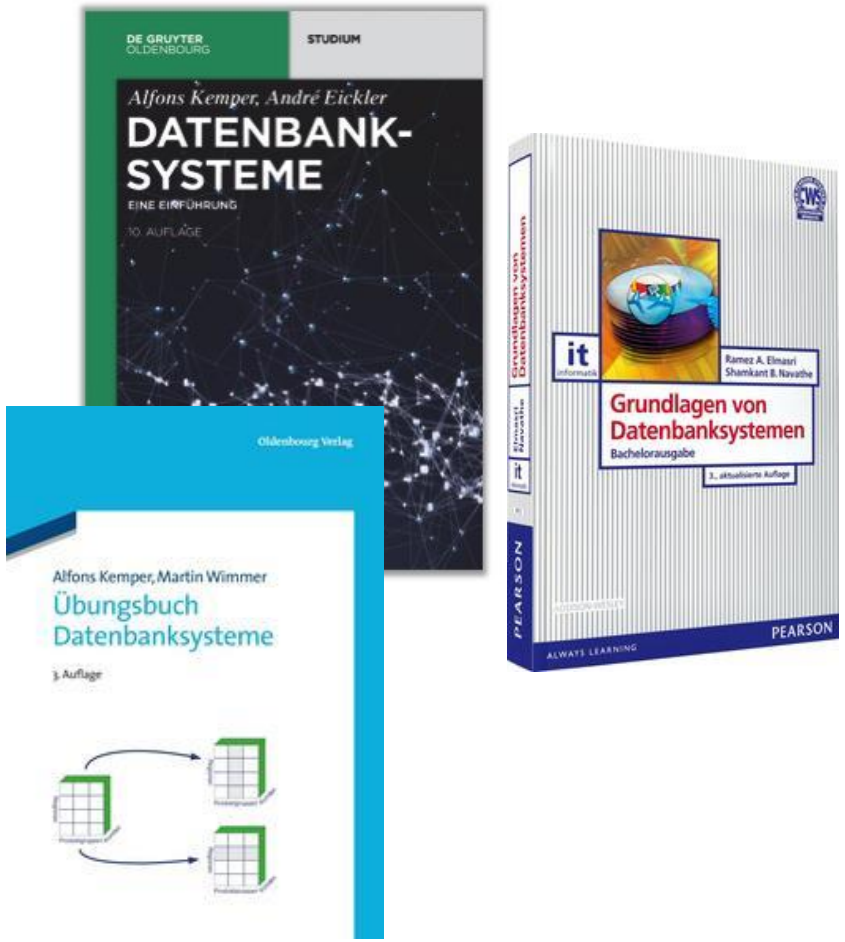
- Die Vorlesungsinhalte werden durch Übungen ergänzt und vertieft.
- Zusätzlich sollen die Studierenden mit PC-Anwendungen eigene Implementierungen einer Datenbank vornehmen, analytische Abfragen generieren und die Regelungen des Datenschutzes anzuwenden.
- Der vollständige Plan der Vorlesungs- und Übungstermine ist im Opal-Kurs hinterlegt.

Basisliteratur

- KEMPER, A.; EICKLER, A.: Datenbanksysteme: Eine Einführung, Oldenbourg: München, 10. Auflage (2015)
- ELMASRI, R.; NAVATHE, S. B.: Grundlagen von Datenbanksystemen: Bachelorausgabe Pearson Studium: München 2009
- Kemper, A.; Wimmer, M.: Übungsbuch Datenbanksysteme. Oldenbourg, 3. Auflage, 2012

<u>Ergänzende Literatur:</u>

- WIEKEN, J. H.: Ernsthaft verstehen - SQL (Band 1 und Band 2), Service Value-Fachbücher-Verlag: Hermannsburg, aktuelle Auflage
- SCHLAGETER, G.; STUCKY, W.: Datenbanksysteme: Konzepte und Modelle, Vieweg+Teubner Verlag: Stuttgart, aktuelle Auflage
- VOSSEN, G.: Datenmodelle, Datenbanksprachen und Datenbankmanagement-Systeme, Oldenbourg: München, aktuelle Auflage
- Laudon, Kenneth C.; Laudon, Jane P.; Schoder, Detlef: Wirtschaftsinformatik, Eine Einführung (3. Auflage, 2015)



DHSN
DUALE HOCHSCHULE
SACHSEN

Organisation der Lehrveranstaltung

Historische Entwicklung

Datenbankansatz

Weitere Datenbankmodelle

Aktuelle Entwicklungsrichtungen

Fangen wir mal von ganz vorn an...

- **Datenspeicherung viel früher.....mit dem Kerbholz**
- mit Kerbhölzern arbeitete man seit Jahrtausenden
- und bis ins 19. Jahrhundert arbeitete selbst die Bank von England mit diesen Utensilien
- wahrscheinlich haben sich auch die römischen Zahlen aus diesem Kerbsystem heraus entwickelt.



Das **Kerbholz**,

(auch *Kerbstock*, *Zählholz, Zählstab*)

ist eine frühzeitliche und mittelalterliche Zählliste, diente meist dazu, Schuldverhältnisse fälschungssicher zu dokumentieren. An einem bestimmten Termin (Zahltag) wurde das Kerbholz präsentiert, mit dem Gegenstück verglichen und zur Zahlung aufgefordert (Quelle: Wikipedia)

(daher übrigens auch der Ausspruch: „etwas auf dem Kerbholz haben“)

Nur etwas früher...das Daten-Chaos





© depositphotos, aldegonde

Quelle: IndiScale
https://www.indiscale.com/de/

Datenorganisation nach dem Dateiansatz (60er Jahre)

Laudon et al. S. 272

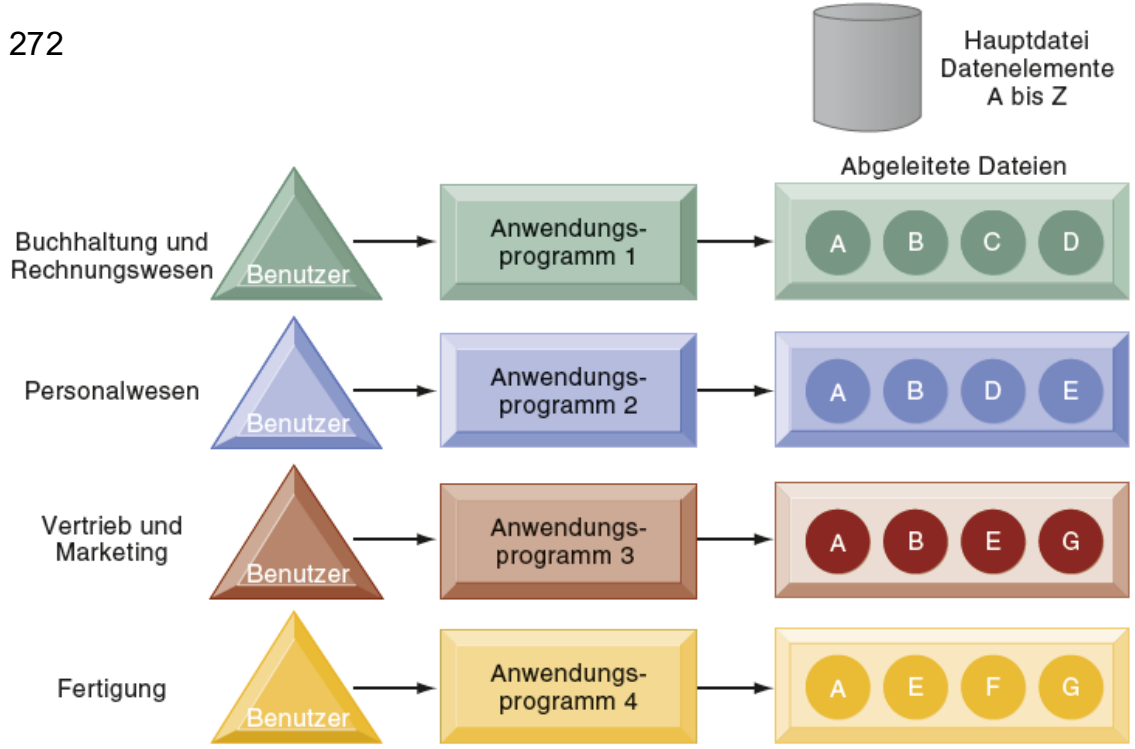


Abbildung 6.2: Datenorganisation nach dem Dateiansatz
Die Verwendung des Dateiansatzes begünstigt die Entwicklung von Anwendungen durch verschiedene Funktionsbereiche eines Unternehmens, die jeweils eigene Datendateien erfordern. Dies führt zu Datenredundanz und -inkonsistenzen, Inflexibilität in der Verarbeitung und einer Verschwendung von Speicherressourcen.

- Informationssysteme in Unternehmen werden oft nicht übergreifend im Voraus geplant
- Jeder Funktionsbereich (z. B. Buchhaltung, Finanzwesen, Produktion, Personalwesen, Marketing) entwickelte oft eigene Systeme getrennt von anderen Funktionsbereichen
- Systeme umfassten Anwendungen und Datenorganisation
- Datenredundanz und Dateninkonsistenzen
- Abhängigkeit zwischen Programm und Daten
- Fehlender Datenaustausch und mangelnde Flexibilität
- Mangelnde Datensicherheit

Probleme des Dateiansatzes

- **Datenredundanz:**
  - Mehrfaches Vorkommen identischer Datenelemente in verschiedenen Dateien
  - Datenredundanz entsteht aufgrund mehrfachen Speicherns derselben Daten an unterschiedlichen Speicherorten
  - Folgen:
    - Verschwenden von Speicherressourcen
    - Mögliches Auftreten von Dateninkonsistenzen
- **Dateninkonsistenzen:**
  - Vorkommen verschiedener Werte für dasselbe Attribut, wenn Änderungen an Datenelementen nicht gleichzeitig an allen redundanten Speicherorten entsprechend nachvollzogen werden
  - Folgen:
    - Anwendungssysteme operieren mit falschen Werten
    - Unterschiedliche Funktionseinheiten haben für dieselben Entitäten bzw. Attribute unterschiedliche Bezeichnungen und Codierungen (fehlende standardisierte Formate)

Probleme des Dateiansatzes

Abhängigkeit zwischen Programm und Daten:

Eine enge Beziehung zwischen den in Dateien gespeicherten Daten und der Software, mit denen diese Daten aktualisiert und verwaltet werden, erfordert bei Änderungen am Programmcode entsprechende Änderungen der Organisation der Datenspeicherung in den zugehörigen Dateien. Dieser Zusammenhang gilt ebenfalls für den umgekehrten Fall.

Fehlender Datenaustausch und mangelnde Flexibilität:

In Dateien organisierte Daten sind unflexibel gegenüber Auswertungen und Verknüpfungen, da ein gleichzeitiger Zugriff auf mehrere Attribute und eine entsprechende Auswertung der Datenelemente zeitaufwendige Such- und Sortierverfahren erfordert

Folge: Datenaustausch zwischen verschiedenen Anwendungssystemen findet in der Regel nicht statt

Mangelnde Datensicherheit

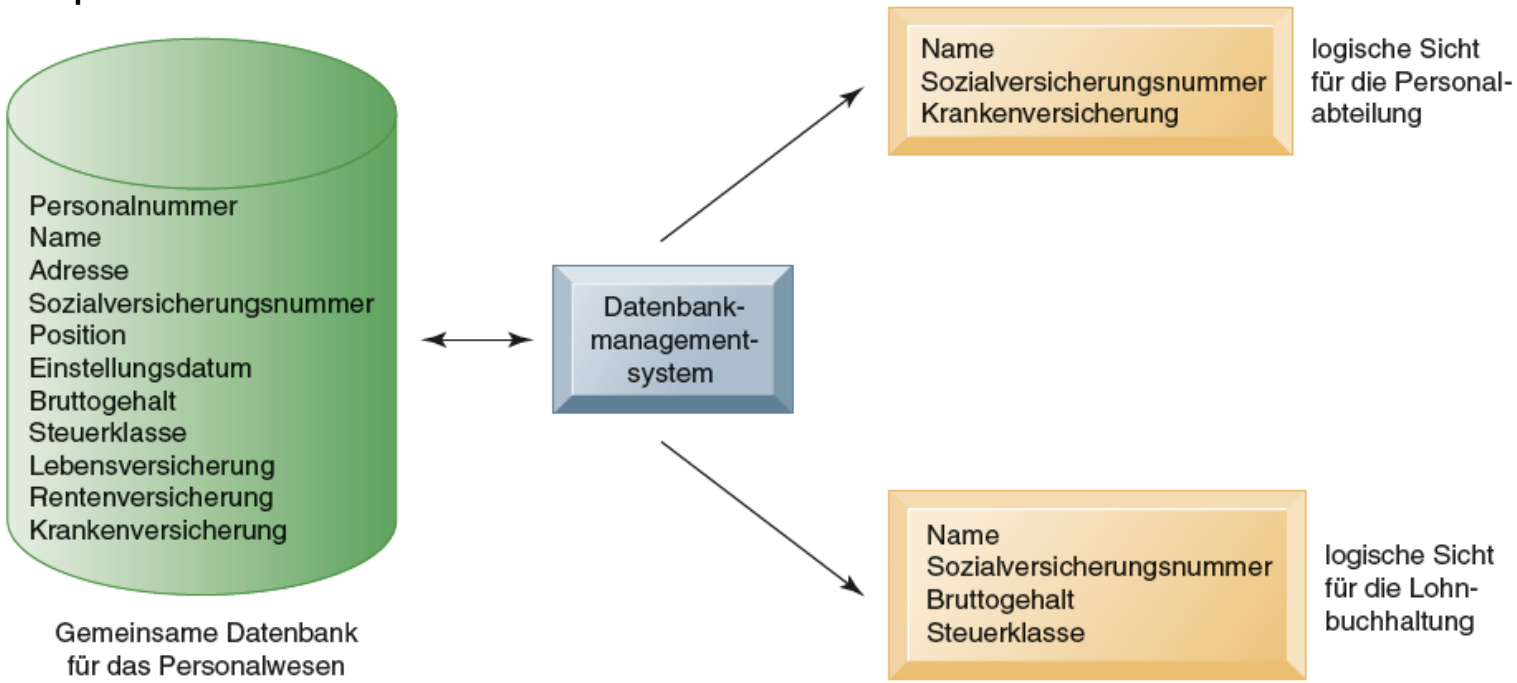
Aufwendige Verwaltung von Dateien an mehreren unterschiedlichen Speicherorten durch die einzelnen Funktionsbereiche
Folge: Kontrolle auf Datenzugriff vom Management, kaum kontrollierbar

Verlust von Daten möglich (außer Komplett-Backup keine Recovery

→ hohe Kosten (wiederholte Dateiverwaltungs-Lösungen)

Lösung: Datenbankansatz

Beispiel: Personaldatenbank



Datenbankmanagementsystem (DBMS):

Sammlung von Programmen zum Erstellen und Verwalten einer Datenbank, die es mehreren Anwendungen gleichzeitig ermöglicht, die von ihnen benötigten Daten zu speichern, zu extrahieren und zu manipulieren, ohne jeweils eigene Dateien erstellen zu müssen.

Datenbanktechnologie der 60er Jahre

1961: erstes allgemeines DBMS: "Integrated Data Store“ IDS

- Entwickelt durch Charles Bachman (Turing Award 1973) bei GE
- Basis für das Netzwerk-Datenmodell(CODASYL)

1965-70: allgemeine Dateisysteme kommen auf

- Entwicklung von Unix
- Erste verteilte DBMS

IBM DBMS: Information Management System (IMS)

- Entwickelt für die Verwaltung der in der Apollo-Mission zum Mond eingesetzten Bauteile
- Basis für hierarchisches Datenmodell
- Hohe Ausfallsicherheit und Performance → Einsatz in Banken, Versicherungen etc. bis heute



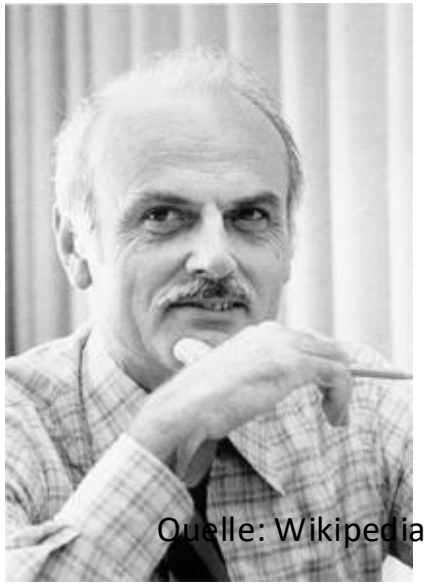
Quelle: IBM

Netzwerkdatenmodell (CODASYL)

- Erste Spezifikation von CODASYL(definiert durch die Conference on Data SYStems Languages)
- Einbettung hauptsächlich in COBOL
- Massive Implementierung von CODASYL-Systemen in den 1970ern
- Ebenso wie IMS heute noch vielfach im Einsatz

Datenbanktechnologie der 70er Jahre

- **1970: E.F. Codd von IBM stellt das relationale Datenmodell vor**
  - Codd,E.F.:A relational model of data for large shared databanks. Communications of the ACM, 1970 (13)
  - Datenbankmodell basierend auf mathematischen Grundlagen
  - Relation als einzige Datenstruktur
  - 1981 Turing Award
- **IBM System/R Prototyp**
  - Ende70er: Brauchbarkeit des relationalen Modells bewiesen
  - SQL(Structured Query Language) entwickelt
  - IBM verschlief dann aber die Kommerzialisierung, DB2 erst 1983



Quelle: Wikipedia

Relationale Datenbanktabellen

LIEFERANT

Spalten (Attribute, Felder)

Lieferantennummer	Lieferantenname	Straße	Stadt	Land	Postleitzahl
8259	CBM Inc.	74 5th Avenue	Dayton	OH	45220
8261	B. R. Molds	1277 Gandolly Street	Cleveland	OH	49345
8263	Jackson Composites	8233 Micklin Street	Lexington	KY	56723
8444	Bryant Corporation	4315 Mill Drive	Rochester	NY	11344

Zeilen (Datensätze, Tupel)

Schlüsselfeld (Primärschlüssel)

ARTIKEL

Artikelnummer	Artikelbeschreibung	Artikelpreis	Lieferantennummer
137	Türschlossfalle	22.00	8259
145	Seitenspiegel	12.00	8444
150	Türdichtung	6.00	8263
152	Türschloss	31.00	8259
155	Kompressor	54.00	8261
178	Türgriff	10.00	8259

Primärschlüssel

Fremdschlüssel

Relation: Tabelle einer relationalen Datenbank, deren Spalten die Attribute einer Entität bestimmen, d.h. den Entitätstyp definieren. Die Zeilen können Datensätze aufnehmen, die konkrete Entitäten beschreiben.

Tupel: Datensatz, der in einer Zeile einer Relation gespeichert wird und entsprechend Attributwerte einer konkreten Entität repräsentiert.

Entität: Phänomen, z. B. eine Person, ein Ort, Ding oder Ereignis, über das Daten gespeichert werden sollen.

Attribut: Eigenschaft, die eine bestimmte Entität beschreibt

Primärschlüssel: Attribut bzw. Datenelement eines Datensatzes, das die Instanzen dieses Datensatzes eindeutig identifiziert, sodass sie abgerufen, aktualisiert und sortiert werden können.

Datenbanktechnologie der 80er Jahre

- **Erste Datenbanksysteme für PC**
  - Erster IBM PC mit (MS-) DOS dBase, Paradox etc.
  - Meist nicht mehrbenutzerfähig und kein Transaktionskonzept
- **Weiteres Wachstum**
  - Laut ANSI/SPARC-Umfrage über 100 relationale DBMS ▪ DB2, Oracle, Sybase, Informix
  - Erster SQL Standard, 1989 SQL-2
- **Trends in den 80er Jahren**
  - Client-Server-Architektur
  - Networking (ISO/OSI-7-Ebenen Modell) und verteiltes Datenmanagement
  - Deduktive DBMS, OODBMS



Quelle: Wikipedia

Datenbanktechnologie der 90er Jahre

- **Erweiterung der DBMS-Funktionalität**
  - räumliche, temporale und Multimedia-Daten
  - Kommerzielle objektorientierte Datenbanken
  - Kommerzielle objekt-relationale Datenbanken
  - MySQL 1994
- **Mehrrechner-Datenbanksysteme**
  - Räumliche Verteilung, Rechnerkopplungen
  - Standards für Datenabfrage und -austausch (SQL2, PDES, STEP)
  - Datenbanksysteme auf parallelen Architekturen (SMP, MPP)
- **XML-Datenbanksysteme**
  - Native XML-Datenbanken, z.B. Tamino, eXist-db (Open Source)
  - XML-Erweiterungen für relationale DBMS (z.B. verfügbar in Oracle, DB2, SQL Server, MySQL, ...)

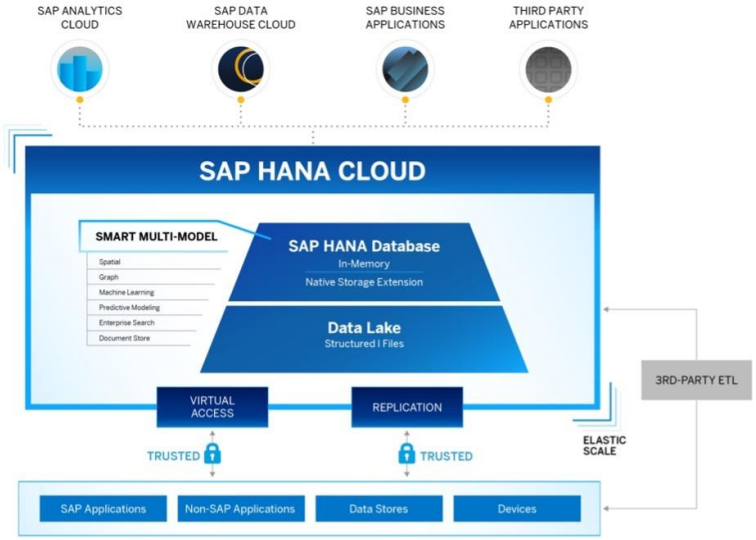
Datenbanktechnologie seit 2000

Stärkerer Anwendungsbezug im DBS-Einsatz

- Operativ: Workflow-Systeme, Unterstützung des B2B/B2C,...
- Analytisch: DataWarehousing, DataMining
- Mobil: MobileDatenbanken

In Memory, Massive Parallel – aber relational!

"Performance at Speed of Thought",besonders für Datenanalysen, Hauptspeicher-(und nicht festplatten-) basierte DBS, getrieben durch leistungsfähige x86-Hardware mit großen Hauptspeichern; Beispiele: SAP High Analytics Appliance (HANA) oder Exasol



https://blogs.sap.com/2022/01/13/all-you-want-to-know-on-sap-hana-cloud/

NoSQL Systeme (Not Only SQL)

- Massive Skalierbarkeit im Cluster für Web-Scale-Datenmanagement
- Auf Kosten von Transaktionssicherheit und Funktionalität (Benutzerschnittstelle, Rollen/Rechte- Konzepte etc.)
- Integrieren verteilte Berechnungsverfahren wie MapReduce
- Klassen: Dokumenten-orientiert(CouchDB,MongoDB), Key-Value-DB (Redis,Riak, Membase), Column Store (Cassandra, HBase), Graph-DB (Neo4J, sones)

Datenbanksysteme in Cloud - Umgebungen

DB-Engines Ranking

424 Systeme im Ranking, August 2025

Rang Aug 2025	Rang Jul 2025	Rang Aug 2024	DBMS	Datenbankmodell	Punkte Aug 2025	Punkte Jul 2025	Punkte Aug 2024
1.	1.	1.	Oracle	Relational, Multi-Model	1220,70	+3,64	-37,78
2.	2.	2.	MySQL	Relational, Multi-Model	915,46	-25,26	-111,40
3.	3.	3.	Microsoft SQL Server	Relational, Multi-Model	754,15	-16,99	-61,02
4.	4.	4.	PostgreSQL	Relational, Multi-Model	671,25	-9,63	+33,87
5.	5.	5.	MongoDB	Document, Multi-Model	395,58	-8,25	-25,40
6.	6.	↑ 7.	Snowflake	Relational	178,90	+2,73	+42,93
7.	7.	↓ 6.	Redis	Key-value, Multi-Model	147,19	-2,53	-5,52
8.	8.	↑ 9.	IBM Db2	Relational, Multi-Model	127,31	-0,20	+4,30
9.	↑ 12.	↑ 15.	Databricks	Multi-Model	115,82	+7,78	+31,36
10.	↓ 9.	↓ 8.	Elasticsearch	Multi-Model	114,27	-4,56	-15,56

DHSN
DUALE HOCHSCHULE
SACHSEN

Organisation der Lehrveranstaltung

Historische Entwicklung

Datenbankansatz

Weitere Datenbankmodelle

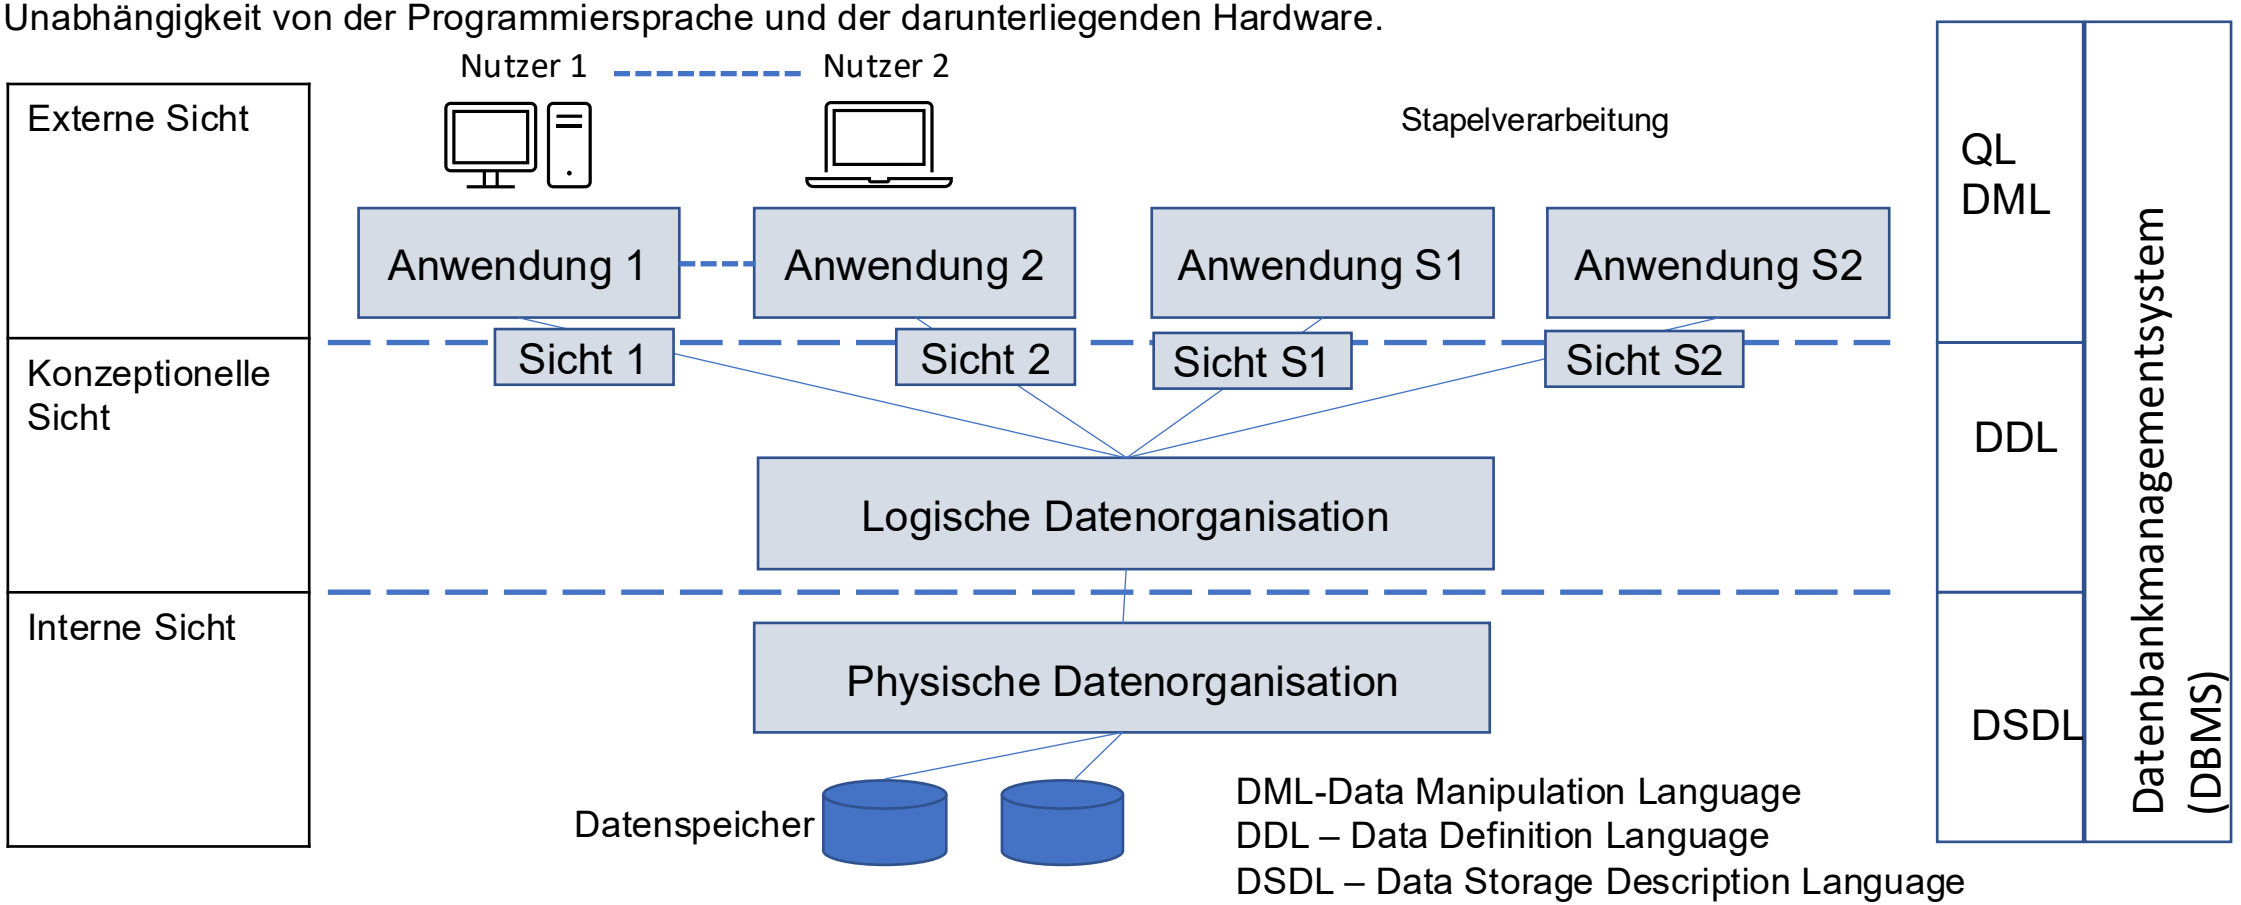
Aktuelle Entwicklungsrichtungen

Gründe für den Einsatz von Datenbanken

- Deklarative Anfragesprachen, d.h. der Benutzer sagt dem DBS ***was*** für Daten geholt werden sollen (und nicht ***wie*** die Daten geholt werden) → weniger störanfällig, da kein Wissen über die tieferen Schichten des DBS benötigt werden)
- Mehrbenutzersynchronisation, d.h. mehrere Benutzer können ohne gegenseitige Beeinflussung gleichzeitig Daten lesen / ändern
- Fehlerbehandlung, d.h. das DBS kann den Zustand zum Zeitpunkt eines Absturzes wieder rekonstruieren (durch das Anlegen und Verwaltung von Logdateien)
- Sicherstellung der Datenintegrität, d.h. das DBS befolgt bestimme angegebene Prinzipien und schützt so vor Programmfehlern und Benutzerfehlern
- Effizienz und Skalierung, d.h. DBS sind für groß angelegte Anwendungen konzipiert und es sind Techniken integriert, die effektiv mit großen Datenvolumen operieren können
- Datenunabhängigkeit, d.h. das DBS „entkoppelt“ Anwendungen von der eigentlichen Struktur und Speicherung der Daten durch Verwendung einer Schichtenarchitektur

3-Ebenen-Modell

Als Grundlage moderner Datenbanksysteme gilt weithin das vom ANSI/SPARC Komitee vorgeschlagene ANSI-3-Ebenenmodell. Ziel des Modells ist die Trennung der internen, konzeptionellen und externen Ebene. Diese drei Ebenen im ANSI-Ebenenmodell gewährleisten eine Unabhängigkeit von der Programmiersprache und der darunterliegenden Hardware.



3-Ebenen-Modell

Externe Sicht/Ebene

Für jede Benutzergruppe wird eine spezielle anwendungsbezogene Sicht der Daten (view) spezifiziert. Die Beschreibung erfolgt durch den application administrator (Anwendungsadministrator) mittels einer DDL (data definition language), der Umgang vom Benutzer erfolgt durch eine DML (data manipulation language) oder durch eine definierte Abfragesprache (QL). Ergebnis ist das externe Schema.

Konzeptuelle Sicht/Ebene/Logische Ebene

Unabhängig von allen Anwenderprogrammen wird die Gesamtheit aller Daten, ihre Strukturierung und ihre Beziehungen untereinander beschrieben. Die Formulierung erfolgt vom enterprise administrator (Unternehmensadministrator) mittels einer DDL. Das Ergebnis ist das konzeptuelle Schema, auch logisches Schema/Sicht oder Datenbankschema genannt.

Interne Sicht/Ebene/Physische Ebene

Hier wird festgelegt, in welcher Form die logisch beschriebenen Daten im Speicher abgelegt werden sollen. Geregelt werden Satzaufbau, Darstellung der Datenbestandteile, Dateiorganisation und Zugriffspfade. Für einen effizienten Entwurf werden statistische Informationen über die Häufigkeit der Zugriffe benötigt. Die Formulierung erfolgt durch den database administrator (Datenbankadministrator). Ergebnis ist das interne Schema.

Datenunabhängigkeit

Physische Datenunabhängigkeit:

- Modifikationen der physischen Speicher- oder Zugriffsstrukturen (z.B. Anlegen oder entfernen einer Indexstruktur) haben keine Auswirkungen auf logische Struktur der Datenbasis (Datenbankschema)
- Benutzer benötigen keine Kenntnisse über physischen Speicherungsort und Speicherungsstruktur der Daten
- Fast alle aktuellen DBS erfüllen die physische Datenunabhängigkeit

Logische Datenunabhängigkeit:

- Änderungen der logischen Gesamtsicht beeinflussen die Anwendungen nicht (Anwendungen sind immun gegen Änderungen am Datenbankschema)
- In der Praxis nur eingeschränkt für einfache Modifikationen realisiert (z.B. lässt sich die Änderung eines Attributs mithilfe einer Sichtdefinition vor dem Anwendungsprogramm verbergen)

Grundoperationen relationaler Datenbanksysteme

Laudon et al. S. 277

AUFTRAG

Auftragsnummer	Bestelldatum	Lieferdatum	Artikelnummer	Bestellmenge
1634	01.08.2009	12.08.2009	152	2
1635	13.08.2009	01.09.2009	137	3
1636	21.08.2009	02.10.2009	145	1

ARTIKEL

Artikelnummer	Artikelbeschreibung	Artikelpreis	Lieferantennummer
137	Türschloss	22,50	4058
145	Türgriff	26,25	2038
150	Türdichtung	6,00	4058
152	Kompressor	70,00	1125

Auswahl über Artikelnummer = 137 oder 152

LIEFERANT

Lieferantennummer	Lieferantenname	Lieferantenadresse
4058	CBM Inc.	44 Winslow, Gary, IN 44950
2038	Ace Inc.	Rte. 101, Essex, NJ 07763
1125	Bryant Corp.	51 Elm, Rochester, NY 11349

Verbund über Lieferantennummer

Artikelnummer	Lieferantennummer	Lieferantenname	Lieferantenadresse
137	4058	CBM Inc.	44 Winslow, Gary, IN 44950
152	1125	Bryant Corp.	51 Elm, Rochester, NY 11349

Projektionen auf ausgewählte Spalten

Abbildung 6.5: Die drei Grundoperationen relationaler Datenbanksysteme
Mithilfe der Operationen Selektion (select), Verbund (join) und Projektion (project) können in diesem Beispiel Daten aus zwei verschiedenen Tabellen kombiniert werden, sodass nur ausgewählte Attribute angezeigt werden.

Selektion (select):

Teilmenge von Daten, die aus allen Datensätzen der Relation bestehet, die die angegebenen Kriterien erfüllt

Verbund (join):

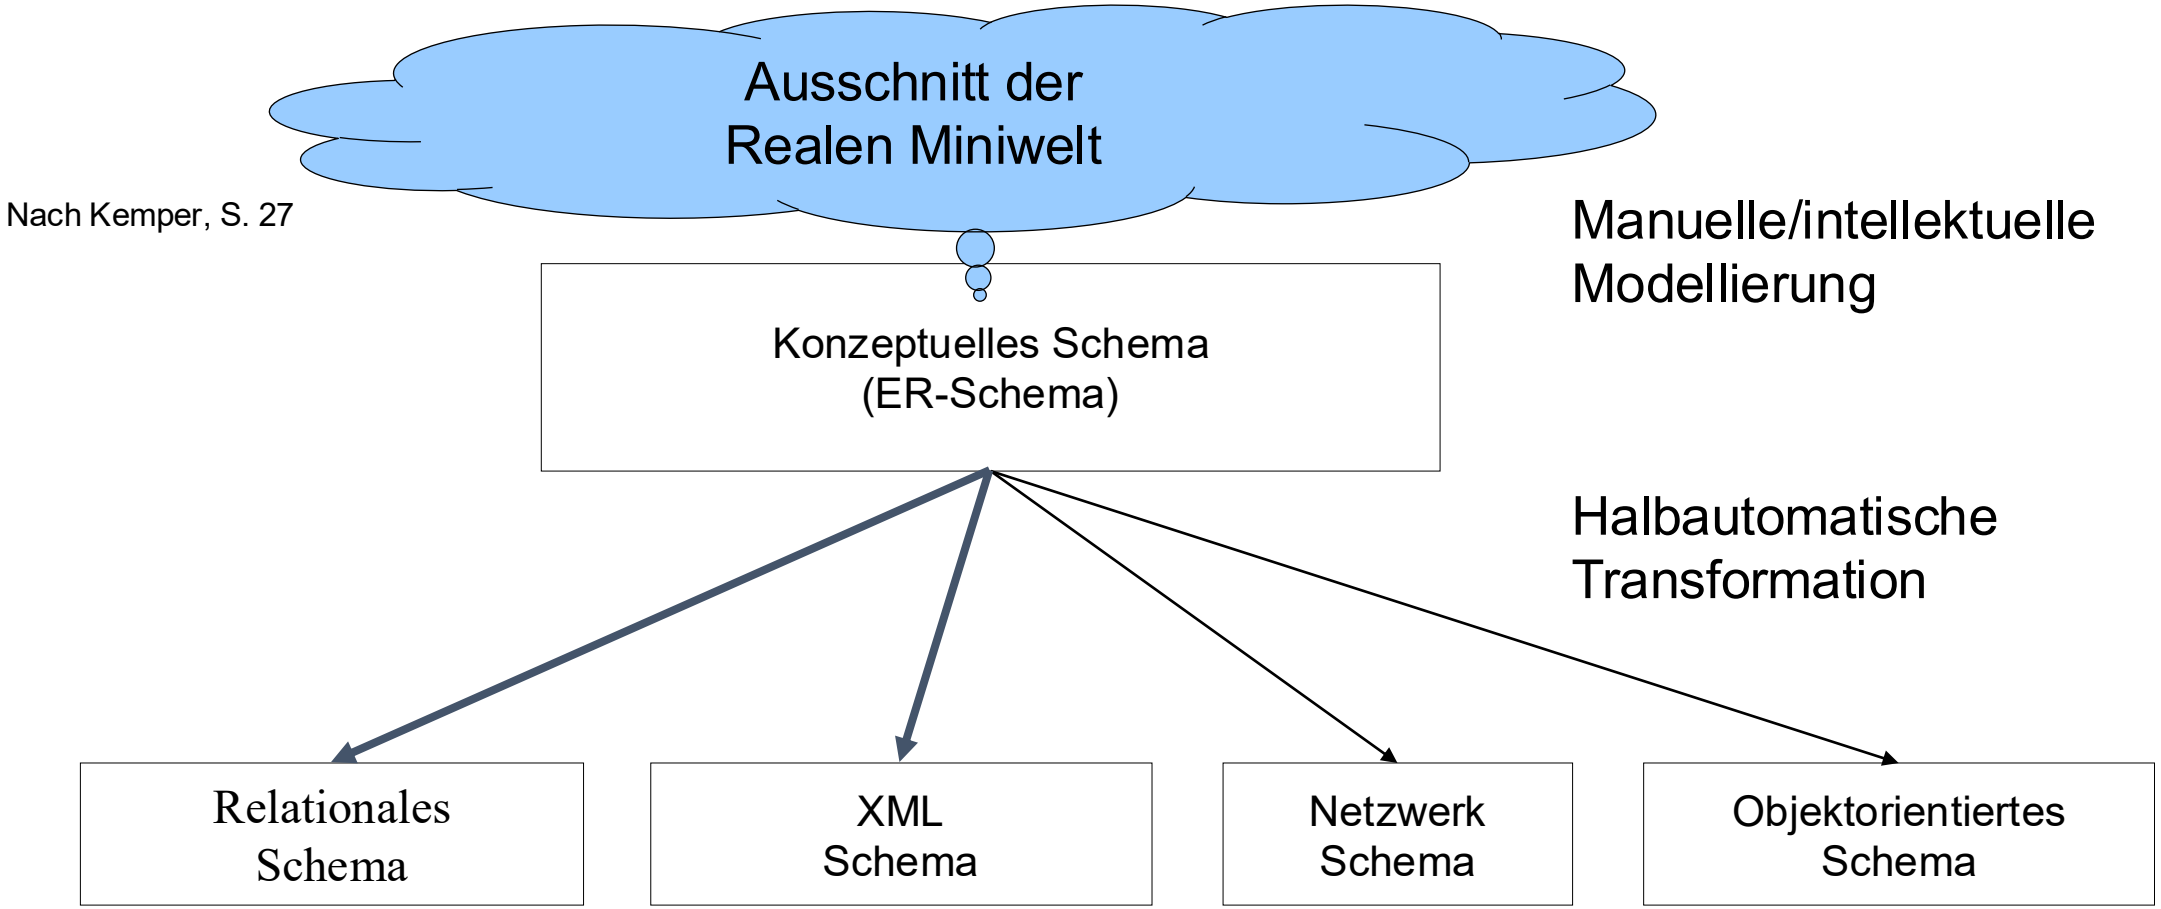
Kombination von Relationen über einen Schlüssel

Projektion (project):

Auswahl von einzelnen Spalten (Attributen)

Datenmodellierung

Datenmodell = Infrastruktur für die Modellierung der realen Welt



Datenmodelle

Netzwerkmodell oder hierarchisches Modell

- Oft als satzorientierte Datenmodelle bezeichnet (Netzwerk- oder hierarchische Beziehungen zwischen Daten)
- Nur noch historische Bedeutung (aber Altinstallationen mit IBM IMS oder Siemens UDS werden noch immer betrieben)

Relationales Datenmodell

- Heute marktbeherrschend, siehe folgende Seiten

Objektorientiertes und objekt-relationales Datenmodell

- Mechanismen der objektorientierten Programmierung (komplexe Objekte mit Struktur und operationaler Komponente/Verhalten, Vererbung von Eigenschaften usw.) werden auf das Datenmodell übertragen
- Beim objekt-relationalen Modell werden einzelne Elemente des objektorientierten Ansatzes mit dem relationalen Modell kombiniert (z.B. können einzelne Attribute einer Relation auch Objekte sein).

Deduktives Datenmodell

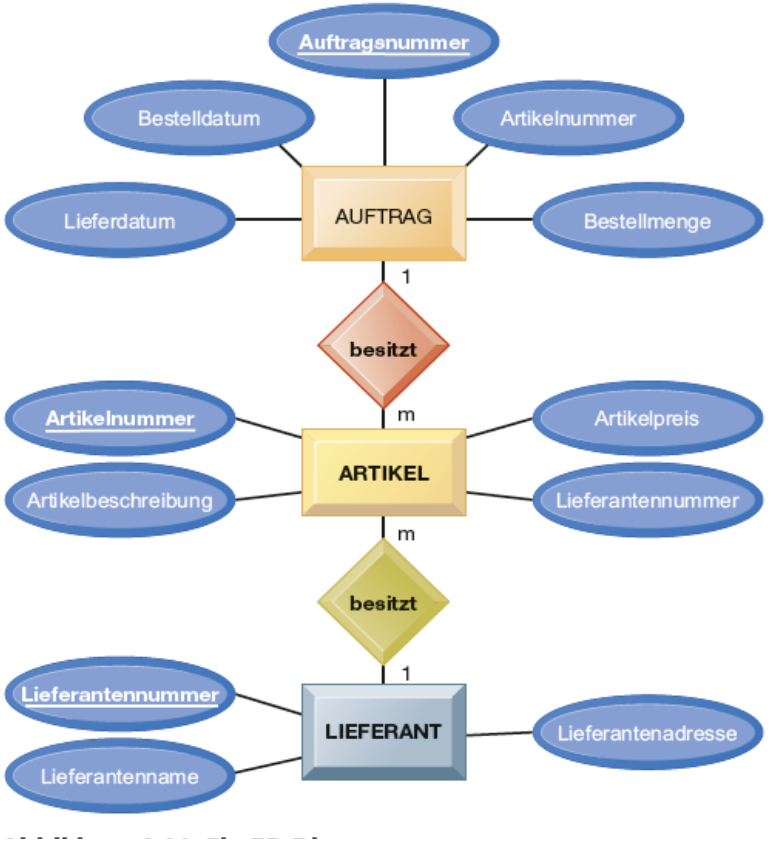
- Erweiterung des relationalen Datenmodells um eine Regel- oder Deduktionskomponente

XML

- XML hat sich besonders als Datenaustausch-Format zwischen heterogenen, verteilten Anwendungen durchgesetzt
- Kommerzielle relationale Datenbanksysteme bieten aber auch für XML schon weitreichende Unterstützung

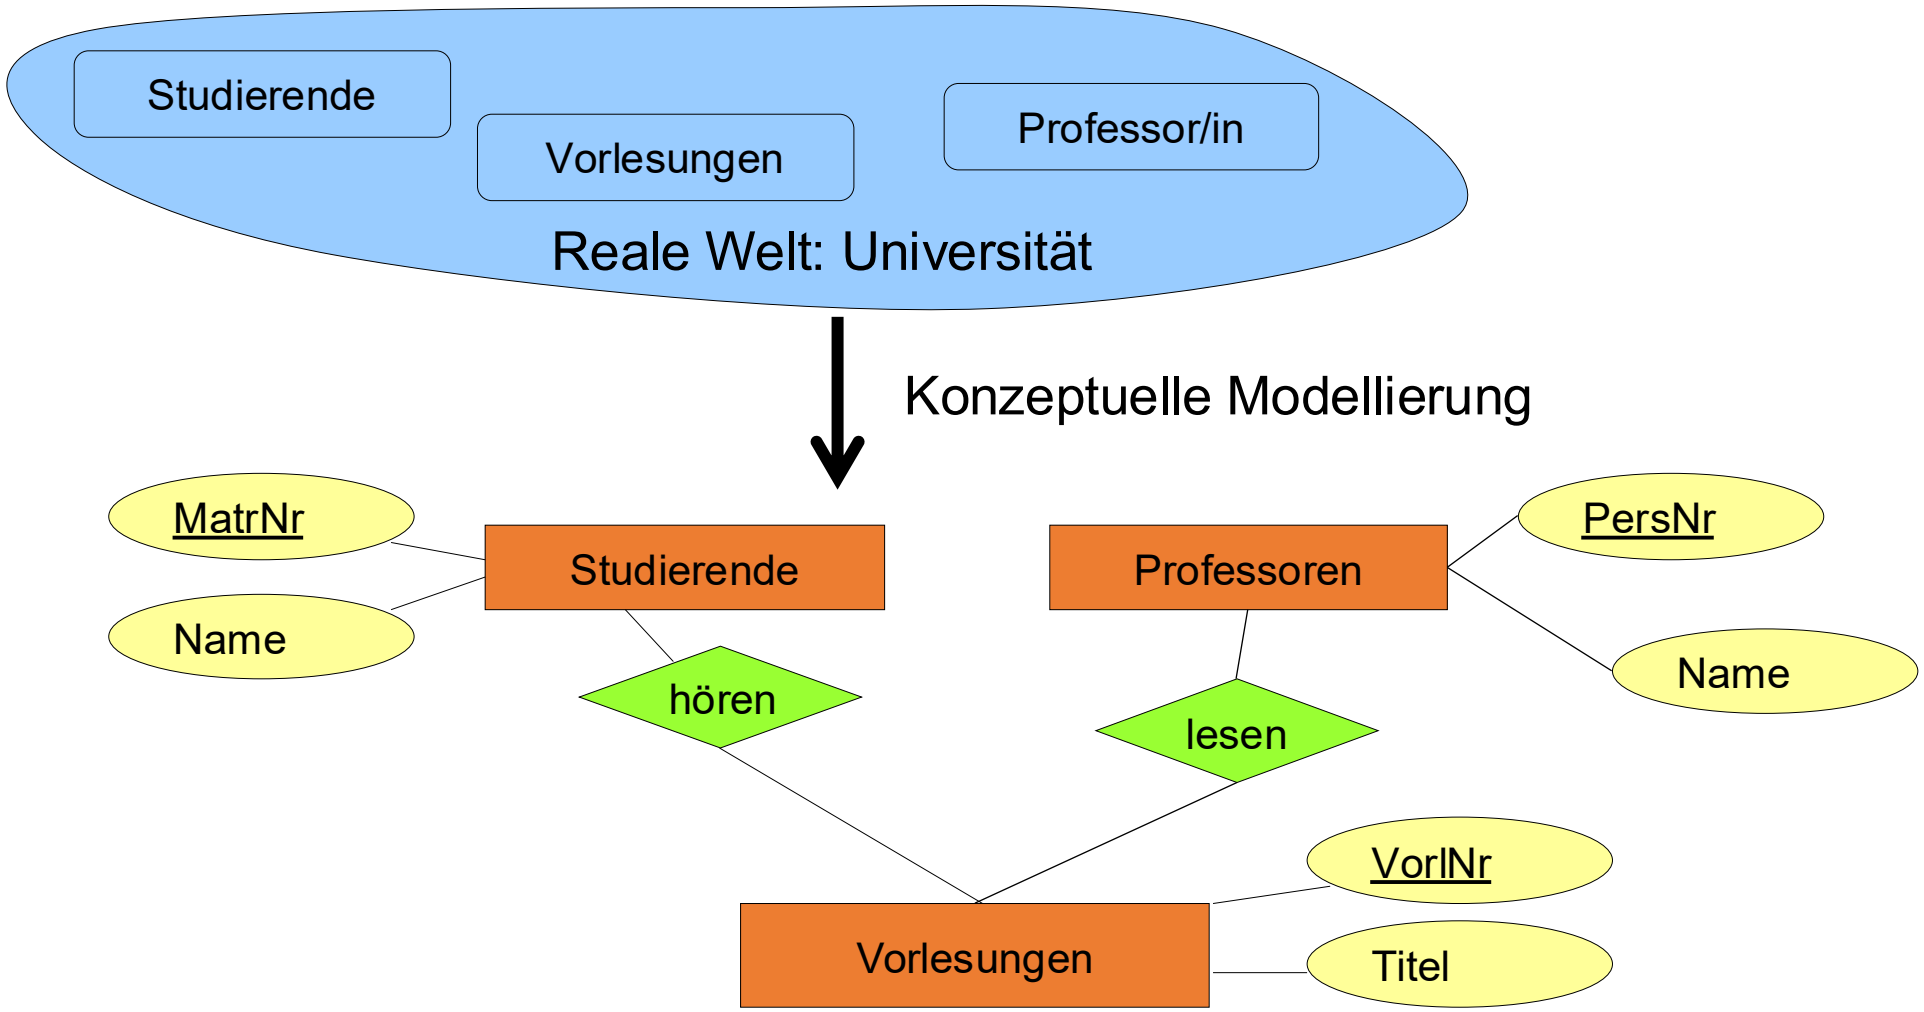
ER-Modell (ERM, Entity-Ralationsship-Modell)

Darstellungsmethode zur Dokumentation des konzeptionellen Datenbankschemas, in dem Entitätstypen mit ihren Attributen sowie die Beziehungstypen zwischen verschiedenen Entitätstypen der Datenbank beschrieben werden.



Beispiel: Uni-Welt

Kemper, S. 28



Datendefinition, Datenabfragen und Berichte

- Organisation,
- Verwaltung und
- Zugriff auf die Daten in der Datenbank.

- Datendefinition(DDL):
  - Komponente eines Datenbankmanagementsystems, mit der für die einzelnen Datenelemente definiert wird, wie sie in der Datenbank dargestellt werden sollen.
  - Definition der Struktur des Datenbankinhalts
  - DDL dient zur Erstellung der Datenbanktabellen und zur Definition der Merkmale aller Tabellenfelder
- die Data Manipulation Language (DML)
- Eine der bekanntesten DDLs / DML ist Structured Query Language (SQL)
- Data Dictionary (Erweitertes Wörterbuch zum Speichern und Verwalten von Informationen über die in einer Datenbank enthaltenen Daten) und

Structured Query Language (SQL)

SQL: ist eine Datenbanksprache zur Definition von Datenstrukturen in relationalen Datenbanken sowie zum Bearbeiten (Einfügen, Verändern, Löschen) und Abfragen von darauf basierenden Datenbeständen. Die Sprache basiert auf der relationalen Algebra, ihre Syntax ist relativ einfach aufgebaut und semantisch an die englische Umgangssprache angelehnt. Ein gemeinsames Gremium von ISO und IEC standardisierte die Sprache unter Mitwirkung nationaler Normungsgremien wie ANSI und DIN. Durch den Einsatz von SQL strebt man die Unabhängigkeit der Anwendungen vom eingesetzten Datenbankmanagementsystem an.

Die Bezeichnung *SQL* wird im allgemeinen Sprachgebrauch als Abkürzung für „Structured Query Language“ (auf Deutsch: „Strukturierte Abfrage-Sprache“) aufgefasst, obwohl sie laut Standard ein eigenständiger Name ist. Die Bezeichnung leitet sich von dem Vorgänger SEQUEL ([ˈsiːkwəl], Structured English Query Language) ab, welche mit Beteiligung von Edgar F. Codd (IBM) in den 1970er Jahren von Donald D. Chamberlin und Raymond F. Boyce entwickelt wurde. SEQUEL wurde später in SQL umbenannt, weil SEQUEL ein eingetragenes Warenzeichen der Hawker Siddeley Aircraft Company ist. (Wikipedia)

```
CREATE TABLE ARTIKEL (
Artikelnummer INTEGER NOT NULL UNIQUE,
Artikelbeschreibung CHAR (100),
Artikelpreis DOUBLE,

Lieferantennummer INTEGER,
PRIMARY KEY (Artikelnummer)
)
```

Laudon et al. S. 279

```
SELECT ARTIKEL.Artikelnummer,
LIEFERANT.Lieferantennummer,
LIEFERANT.Lieferantenname,
LIEFERANT.Lieferantenadresse
FROM ARTIKEL
NATURAL JOIN LIEFERANT
WHERE Artikelnummer = 137 OR Artikelnummer = 152;

SELECT PART.Part_Number, PART.Part_Name, SUPPLIER.Supplier_Number,
SUPPLIER.Supplier_Name
FROM PART, SUPPLIER
WHERE PART.Supplier_Number = SUPPLIER.Supplier_Number AND
Part_Number = 137 OR Part_Number = 150;
```

Abbildung 6.7: SQL-Anweisungen für eine Abfrage, die Ihnen die Anbieter für die Teile der Nummer 137 und 150 zurückliefert.

Relationen (Uni-Welt)

Studierende	
MatrNr	Name
26120	Fichte
25403	Jonas
...	...

hören	
MatrNr	VorlNr
25403	5022
26120	5001
...	...

Vorlesungen	
VorlNr	Titel
5001	Grundzüge
5022	Glaube und Wissen
...	...

Kemper, S. 29

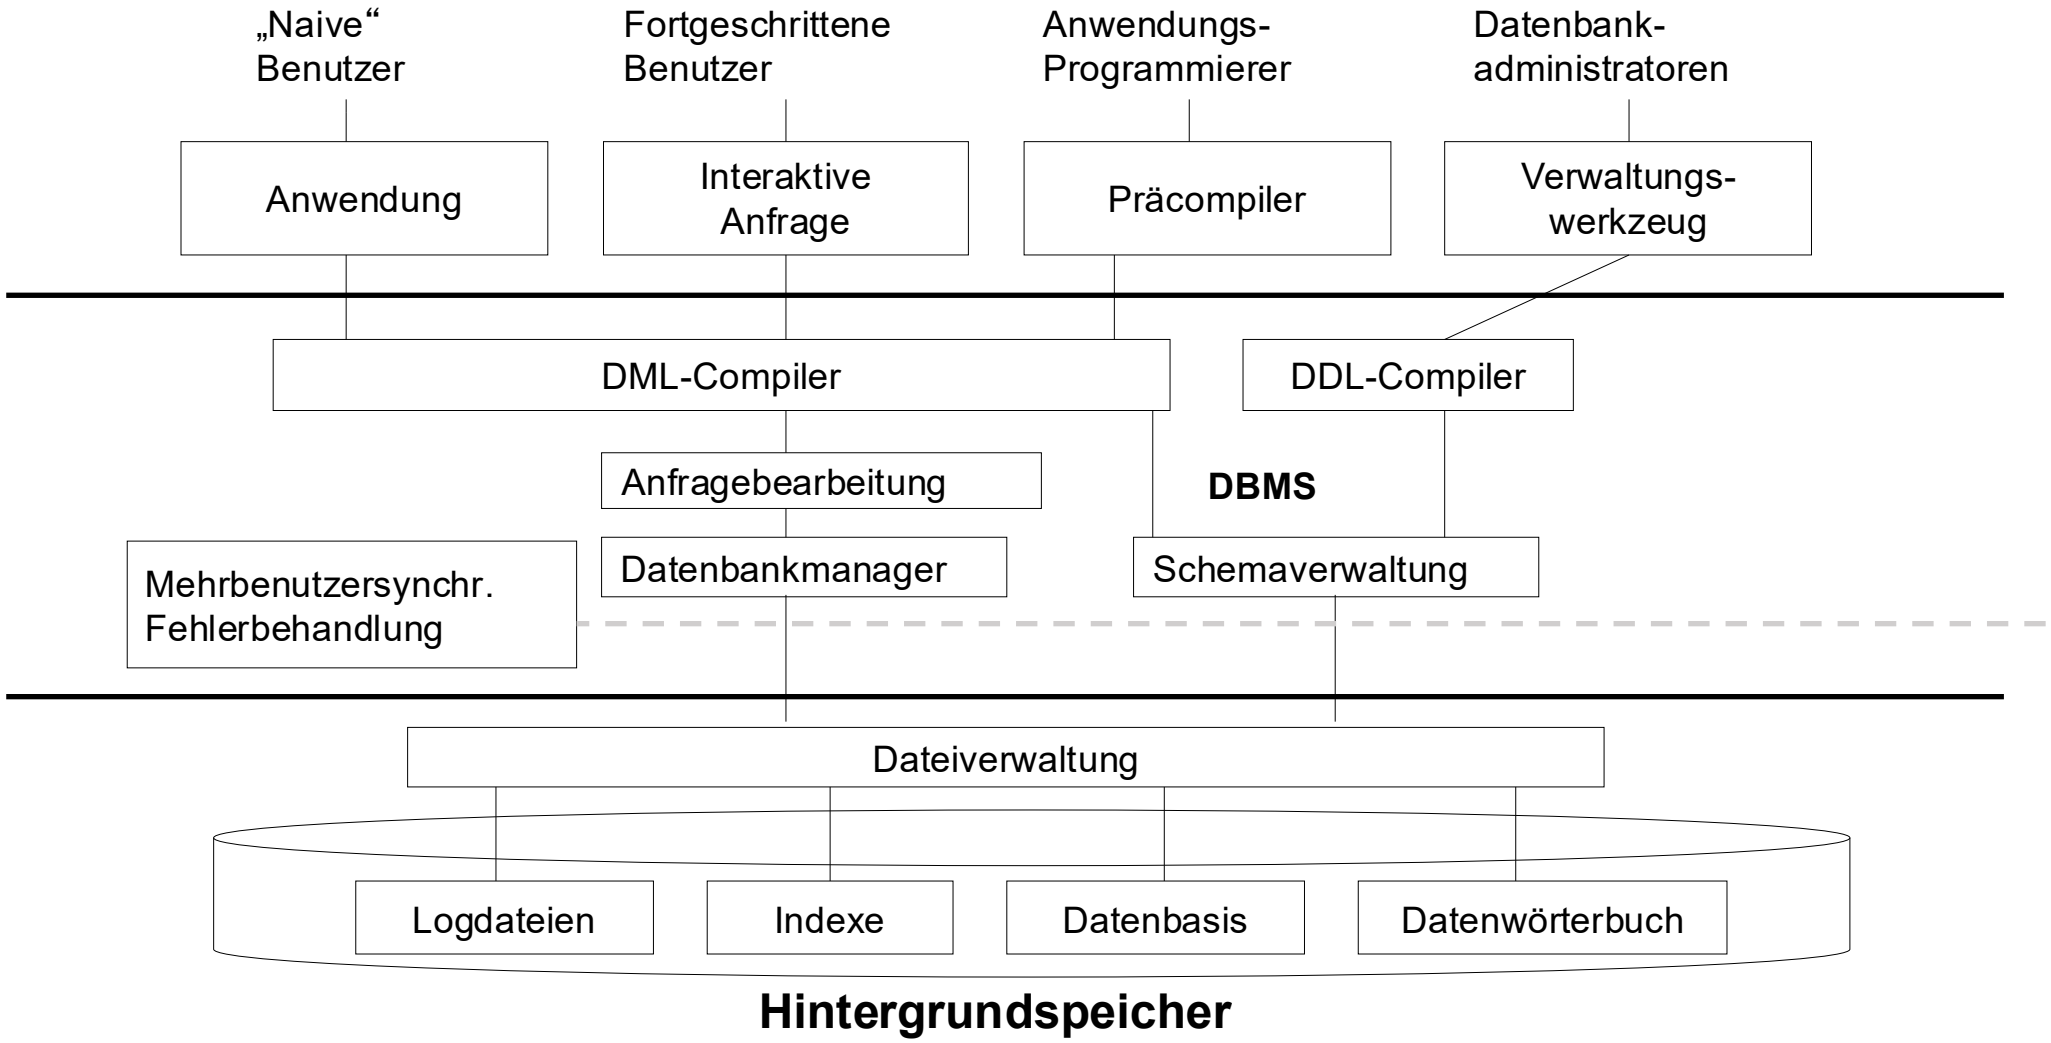
- Die Tabellen stellen die logische Sicht der Datenbank-Nutzer dar
- Für die Manipulation und Abfrage dieser Tabellen wurde eine standardisierte DML namens SQL entworfen

```
Select Name
From Studierende, hören, Vorlesungen
Where Studierende.MatrNr = hören.MatrNr  and
      hören.VorlNr = Vorlesungen.VorlNr  and
      Vorlesungen.Titel = `Grundzüge´;
```

```
update   Vorlesungen
set      Titel = `Grundzüge der Logik´
where    VorlNr = 5001;
```

Achtung: Das Datenbankschema (also die Struktur der Tabellen, die Anzahl der Spalten, Wertebereiche usw.) werden nur sehr selten geändert!

(vereinfachte) Architekturübersicht eines DBMS



DHSN
DUALE HOCHSCHULE
SACHSEN

Organisation der Lehrveranstaltung

Historische Entwicklung

Datenbankansatz

Weitere Datenbankmodelle

Aktuelle Entwicklungsrichtungen

Nichtrelationales Datenbankmodell und DB in der Cloud

- Cloud Computing, immense Datenmengen, massive Auslastung der Webdienste und die Notwendigkeit, neue Datentypen zu speichern, verlangen nach Datenbankalternativen zu dem klassischen relationalen Modell
- Unternehmen wenden sich deshalb zunehmend der „NoSQL“-Technologie nichtrelationaler Datenbanken zu. „NoSQL“ wird dabei unterschiedlich aufgelöst, etwa im Sinne von eben nichtrelational oder in jüngerer Zeit im Sinne von „Not only relational“ (SQL = Structured Query Language = standardisierte Abfragesprache für relationale Datenbanken)

NoSQL

- Produkte und Verfahren nichtrelationaler Datenbanken und Datenbankmanagementsystemen. Sie legen ein flexibleres Datenmodell jenseits von „Zeilen und Spalten“ zugrunde und sind dafür ausgelegt, große, auf viele verschiedene Rechner verteilte Datensätze zu verwalten und schnell zu skalieren. Sie eignen sich insbesondere auch für unstrukturierte Daten.
- Legen ein flexibleres Datenmodell zugrunde und sind dafür ausgelegt, große, auf viele verschiedene Rechner verteilte Datensätze zu verwalten und schnell nach oben oder unten zu skalieren.
- Eignen sich besonders gut zur Beschleunigung einfacher Abfragen auf riesigen Mengen von strukturierten und unstrukturierten Daten, einschließlich dem Web, Social Media, Grafiken.
- Beispiele für NoSQL Datenbankmanagementsysteme:
  - Oracle NoSQL Database
  - SimpleDB von Amazon

Verteilte Datenbanken

Laudon et al. S. 284

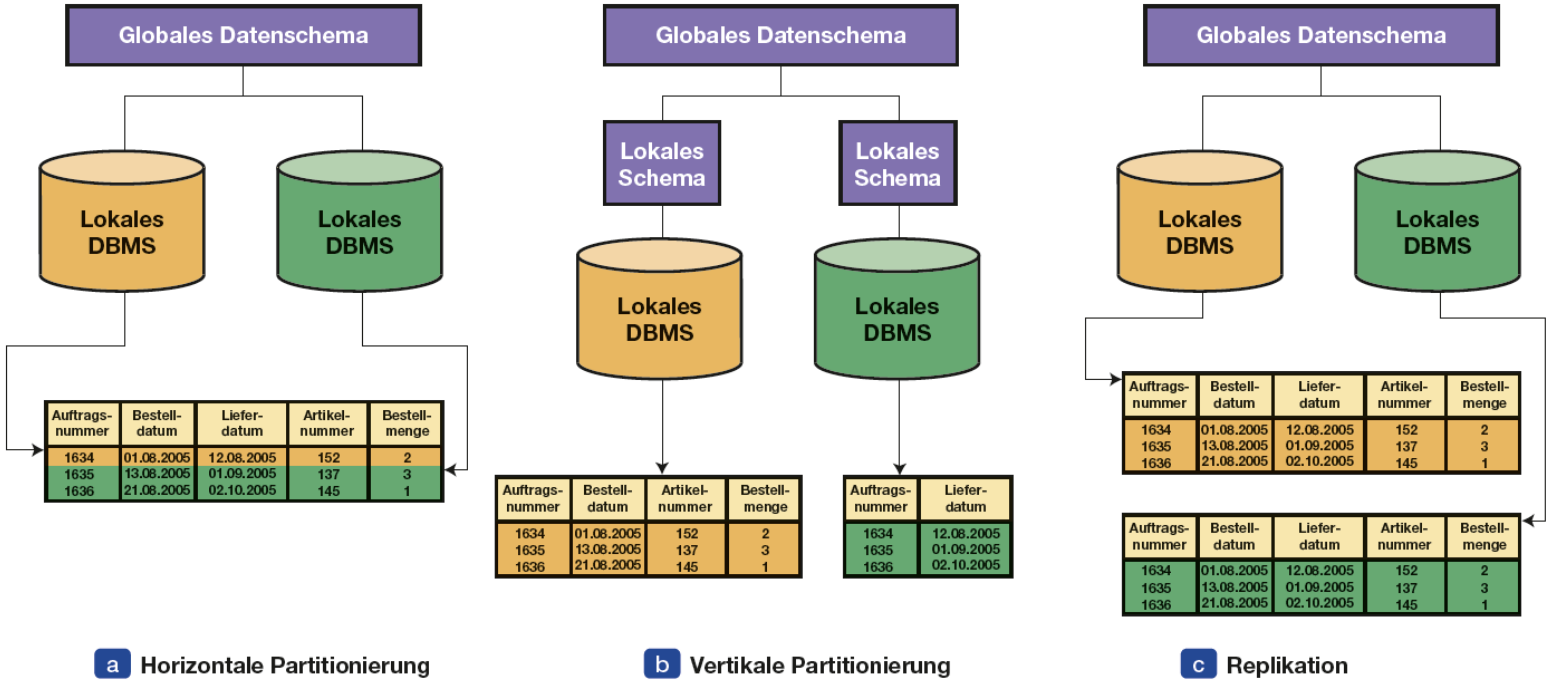


Abbildung 6.12: Verteilte Datenbanken

Es gibt verschiedene Varianten, eine Datenbank zu verteilen. Die Datenbank kann horizontal (a) oder vertikal (b) partitioniert werden, sodass jedes lokale DBMS über die notwendigen Daten für seinen lokalen Bereich verfügt. Die Daten können aber auch auf alle lokalen Datenbankstandorte repliziert werden (c).

Verteilte DB:

- Datenbanksystem, bei dem logisch zusammengehörende Datenbestände einer Datenbank physisch auf mehrere Speicherorte verteilt werden, die über Netzwerke miteinander verbunden sind.

Physischer DB-Entwurf:

- Ansatz einer zentralen Datenbank, die von einem zentralen Rechner oder von mehreren Rechnern einer Client-Server-Umgebung bearbeitet wird.

- Verteilter Ansatz, dessen logisch zusammengehörende Datenbestände an mehreren physischen Speicherorten gespeichert werden, die über Netzwerke miteinander verbunden sind.

DHSN
DUALE HOCHSCHULE
SACHSEN

Organisation der Lehrveranstaltung

Historische Entwicklung

Datenbankansatz

Weitere Datenbankmodelle

Aktuelle Entwicklungsrichtungen

BIG Data – eine Herausfordrung

Webverkehr, E-Mail-Nachrichten und Social-Media-Inhalte (Tweets, Statusmeldungen), Sensoren (in intelligenten Messgeräten, Fertigungssensoren und Stromzählern) sowie elektronische Handelssysteme haben die Datenflut sprunghaft ansteigen lassen.

Daten, die mit der in einem Unternehmen aktuell zur Verfügung stehenden IT-Infrastruktur aufgrund ihres Umfanges oder ihrer Komplexität nicht zu erfassen, zu verarbeiten und zu analysieren sind, werden gemeinhin als Big Data (-Probleme) bezeichnet.

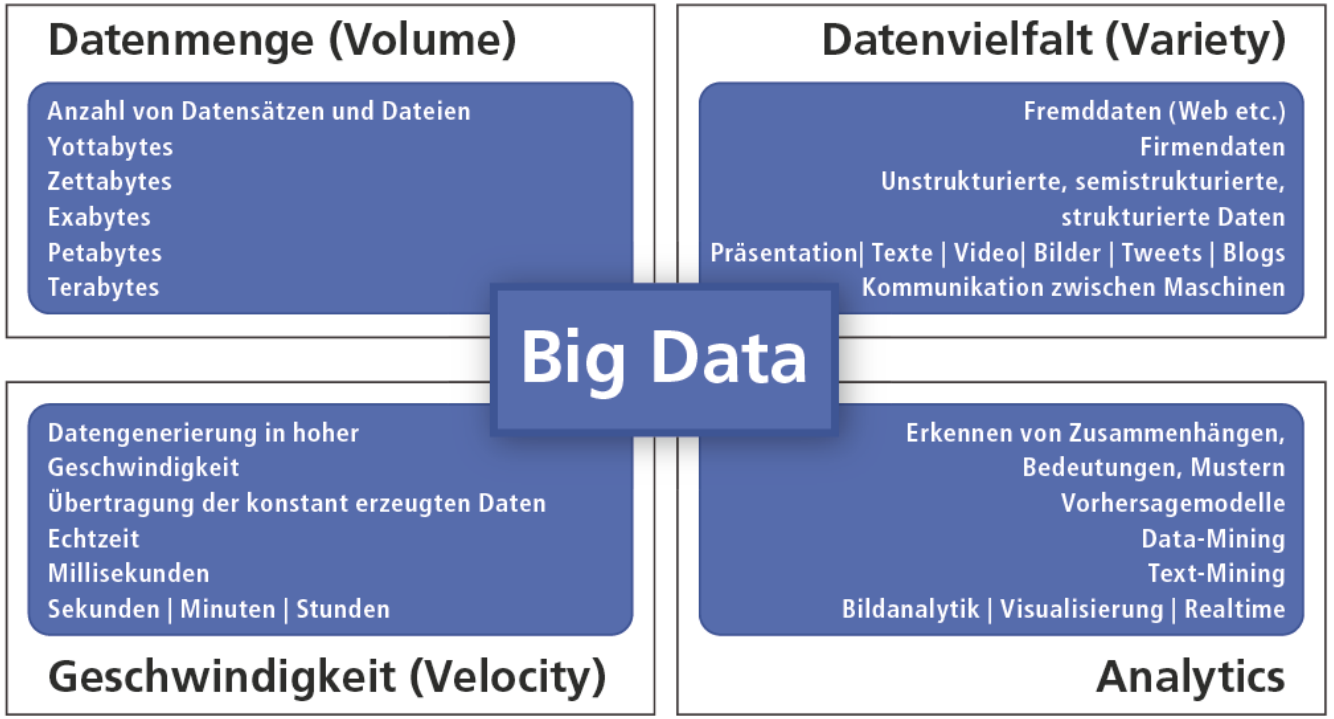


Abbildung 6.13: Merkmale von Big Data.

Quelle: BITKOM, 2015.

Facetten von Big Data

- **Digitalisierungsgrad**
  - Im Jahre 2000 lagen nur ein Viertel aller gespeicherten Daten auf unserem Planeten digitalisiert vor. Heute sind es mehr als 98 Prozent, die digital vorliegen.
- **Datafication**
  - Alles, was ehemals nicht einfach quantifizierbar war, wird nun digital repräsentierbar, mithin speicherbar.
  - Ein Beispiel: Früher war es für den Laien nahezu unmöglich, beliebige Orte auf unserem Planeten mit wenig Aufwand etwa anhand der Höhen- und Breitenangaben zu bestimmen. Heutzutage kann sich jeder mit entsprechenden Instrumenten GPS-Daten verschaffen.
- **Vollerhebungen**
  - Zumindest früher war es sehr aufwendig und teuer, Daten zu erheben.
  - In einigen Kontexten haben wir nun die Möglichkeit, praktisch Vollerhebungen vorzunehmen.
  - Man verfügt de facto über „alle“ Informationen, etwa von einer Zielgruppe, und kann nun beliebig fein – bis aufs Individuum – auflösen, segmentieren und analysieren.

Facetten von Big Data

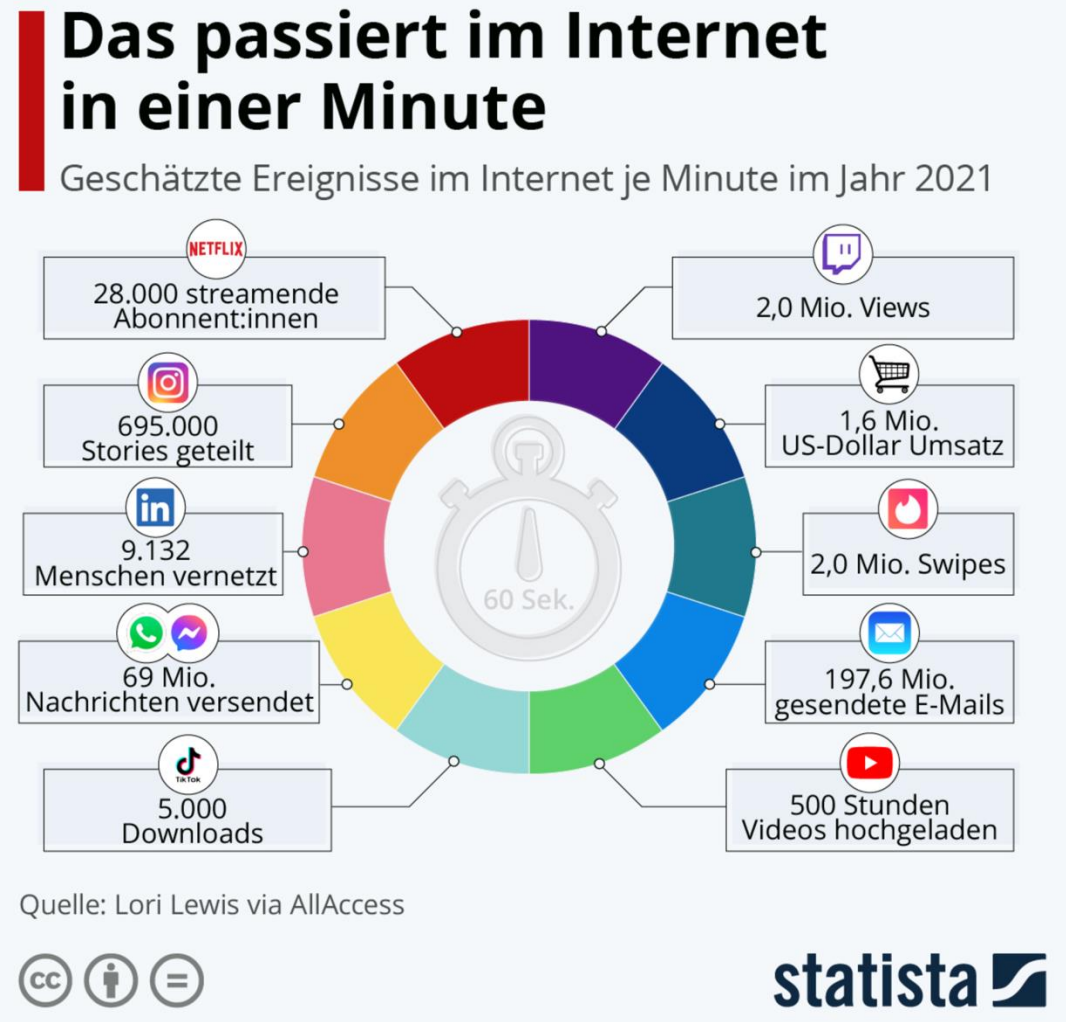
Unaufgeräumte Datenwelten

- In bestimmten Kontexten müssen wir nicht mehr einem als ideal zu bezeichnenden Zustand einer „bereinigten Datenwelt“ zustreben, sondern können auch mit „unaufgeräumten Datenwelten“ akzeptable Ergebnisse erreichen.
- Beispiel: Man kann etwa das Problem der Übersetzung von Texten mit klassischen linguistischen Methoden angehen. Ein völlig anderer Lösungsansatz für dieses Übersetzungsproblem verfolgt Linguee, gegründet von einem Ex-Google-Mitarbeiter. Auf Basis von Millionen von wechselseitig übersetzten Texten erkennen die Linguee-Algorithmen, welche Satzteile wie häufig wie übersetzt wurden.

Korrelation versus Kausalität

- Verschiebung der Bedeutung weg von Kausalität hin zu Korrelaten.
- Weg von einem tieferen Sinn, ausgedrückt durch erklärende Kausalzusammenhänge, hin zu „einfachen“ Aussagen über Muster, womöglich völlig von Kausalität abstrahiert.
- Beispiel: Wenn jemand von A nach B geht, zum Beispiel die Alpen überquert, wäre eine Frage, wie lang man dafür im Durchschnitt braucht. Hierfür ließe sich jetzt ein womöglich kompliziertes Modell aufstellen. Diese Frage lässt sich aber auch anders, im Sinne von Big Data, datengetrieben angehen, hätte man beispielsweise die Daten von beispielsweise 1 Millionen Menschen zur Verfügung (die diese Reise schon unternommen hätten und deren Daten hierfür vorlägen). [Für eine gute datenbasierte Abschätzung wäre vermutlich ein Bruchteil der Daten bereits ausreichend.]

60 Sekunden im Internet – Datenmenge



- Man bräuchte keine erklärenden (Kausal-) Modelle mehr, weil neuerdings alles daten- und mustergetrieben beschreibbar ist und sich daraus Aussagen treffen lassen.
- Zahlreiche Wissenschaftler, sagen, das sei das neue Paradigma der Wissenschaft, „The Fourth Paradigm“.
- Eine Synthese besteht nun darin, dass durchaus die Exploration von Datenmustern die Aufstellung kausaler Modelle informieren kann.
- Ruf nach einem neuen Berufsbild: Data Scientist
- Zu erwarten: „Competing on Analytics“ [Davenport]

Data Warehouse

Eine Datenbank mit Berichts- und Abfragefunktionen, die operative und historische Daten speichert, die aus verschiedenen betrieblichen Systemen extrahiert wurden, und für Managementberichte und Analysen zusammenführt und aufbereitet.

Data Mart: Ein kleines Data Warehouse, in dem ein Teil der Unternehmensdaten für eine spezielle Funktion oder Gruppe von Benutzern aufbereitet und gespeichert wird.

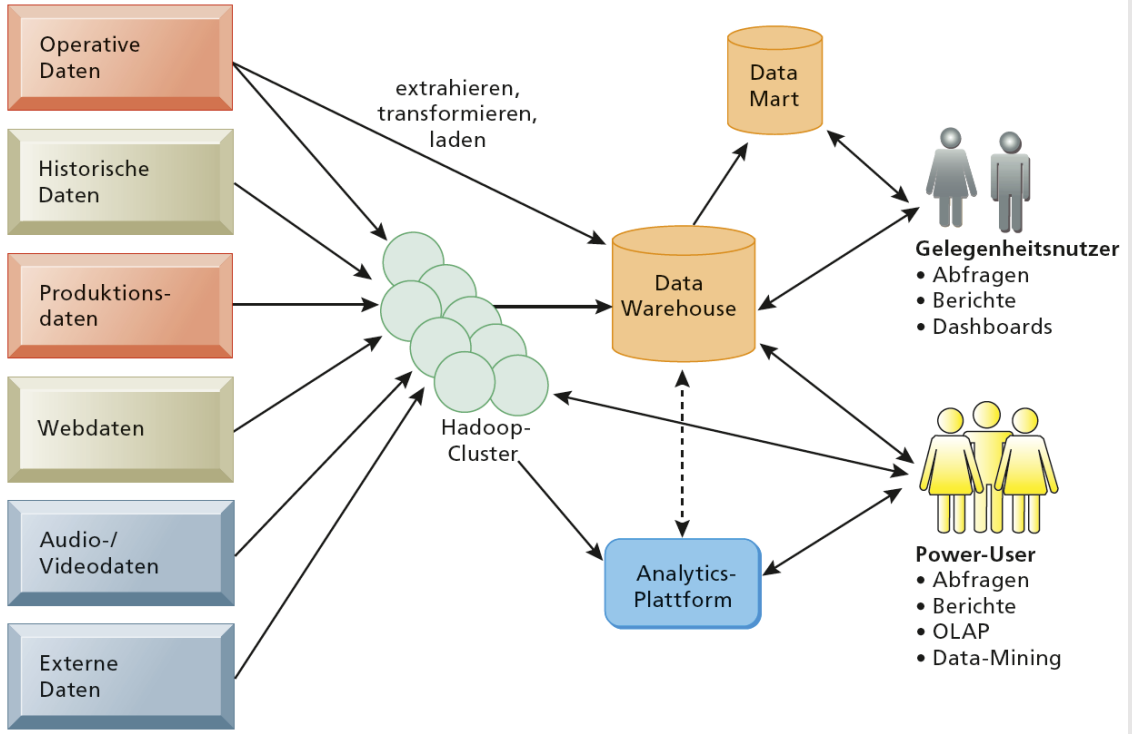


Abbildung 6.15: Komponenten eines Data Warehouse
Eine aktuelle Business-Intelligence-Infrastruktur verfügt über Funktionalität und Tools, um große Mengen an Daten der verschiedensten Typen und aus mehreren Quellen zu verwalten und zu analysieren. Hinzu kommen leicht zu bedienende Abfrage- und Berichte-Tools für den Gelegenheitsnutzer und anspruchsvollere Toolsets für Power-User.

Laudon et al. S. 292

Hadoop ist ein Open-Source-Software-Framework der Apache Software Foundation für die verteilte parallelisierte Verarbeitung von riesigen Datenmengen auf kostengünstigen Rechner-clustern.
Es zerlegt ein Big-Data-Problem in mehrere Teil-probleme, verteilt diese zur Verarbeitung auf Tausende von kostengünstigen Rechnerknoten und packt das Ergebnis in einen kleineren Datensatz, der leichter zu analysieren ist.

Business Intelligence & Analytics

Kommerzielle Datenbankanbieter haben spezielle Highspeed-Analytics-Plattformen entwickelt, die auf relationalen und nichtrelationalen Datenbanktechnologien basieren und für die Auswertung großer Datenmengen optimiert sind.

IBM Netezza zum Beispiel hat eng integrierte Datenbank-, Server- und Speicherkomponenten, die komplexe analytische Abfragen 10- bis 100-mal schneller ausführen können als traditionelle Systeme.

Laudon et al. S. 297

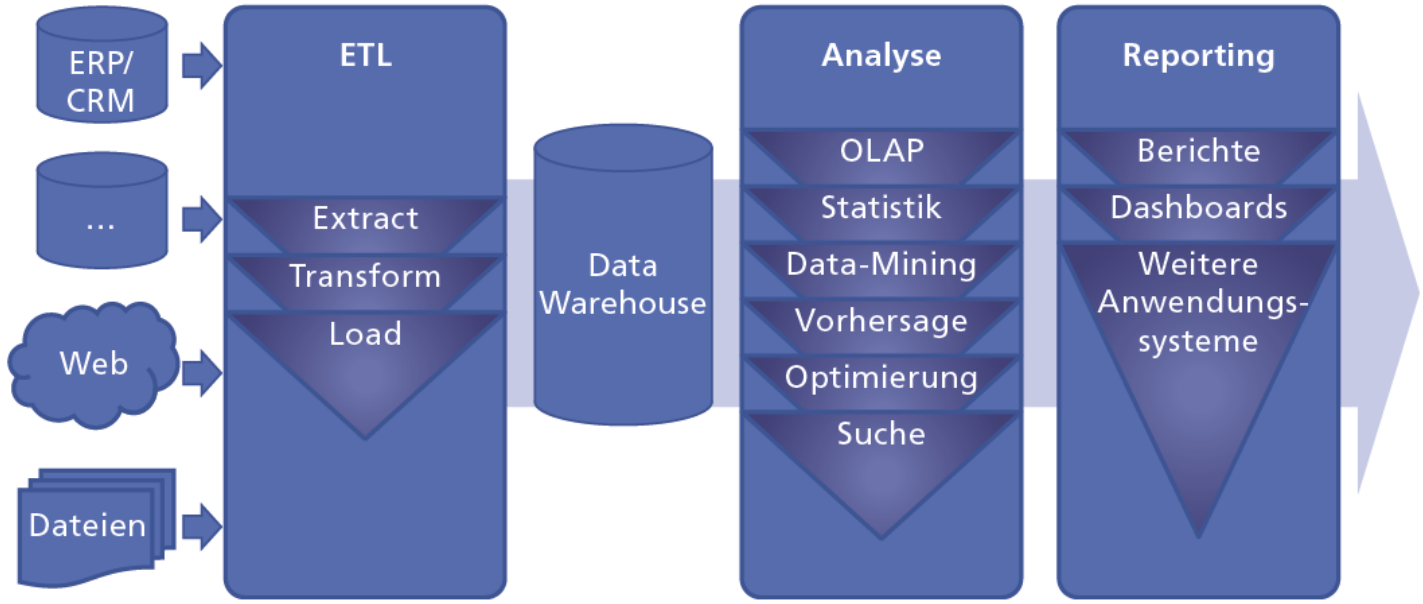


Abbildung 6.16: Business Intelligence & Analytics
Eine Reihe von Techniken wird auf die in verschiedenen Datenbanken gespeicherten Daten angewendet, um Muster herauszufinden und Managern und Angestellten so Hilfestellungen bei ihrer Entscheidungsfindung zu bieten und die Rentabilität eines Unternehmens zu steigern.

Quelle: S. Chaudhuri, U. Dayal und V. Narasayya, Communications of the ACM 54(8), S. 88-98 (2011).

ETL (Extract, Transform, Load)

Extraction

Zur Datenextraktion muss zunächst ein technischer Zugriff auf die relevanten Datenquellen zumeist über bekannte Schnittstellen oder Konnektoren hergestellt werden.

Transformation

Ziel hierbei ist es, die aus unterschiedlichen Quellen stammenden Daten, die höchstwahrscheinlich unterschiedlich strukturiert sind, in eine einheitliche Datenstruktur zu überführen.

Dabei werden in mehrerlei Hinsicht die Daten integriert und bereinigt, etwa Dubletten entfernt, Datumsformate und Einheiten standardisiert, Aggregationsgrade angeglichen.

Laden

Das Laden des transformierten Datensatzes umfasst die technische Anbindung der ETL-Komponente an ein Data Warehouse.

Online Analytical Processing (OLAP)

Laudon et al. S. 298

OLAP
Technik, um Daten nach mehreren Dimensionen bzw. aus mehreren Perspektiven zu analysieren.

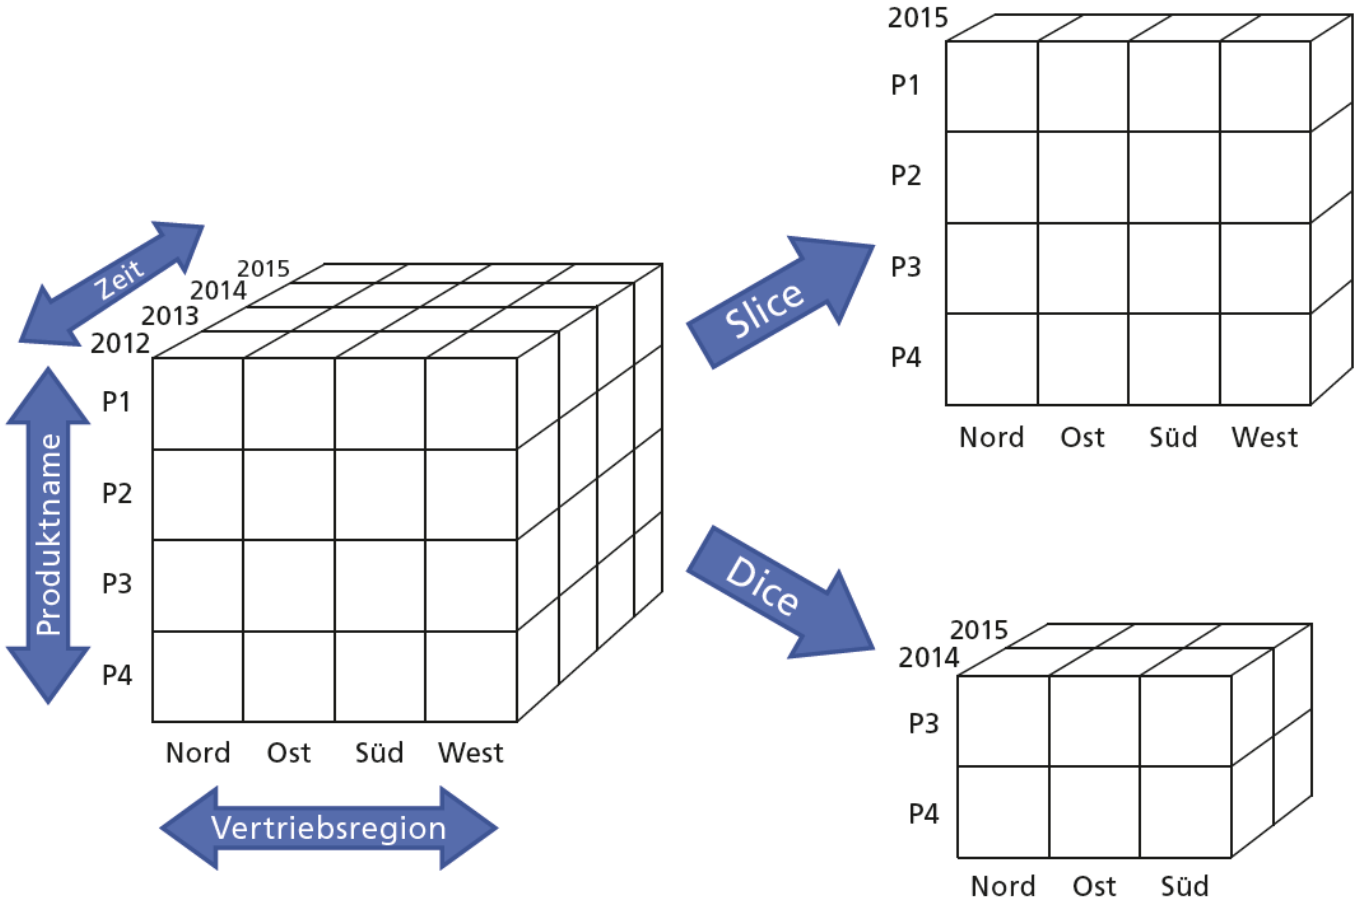


Abbildung 6.17: OLAP-Würfel sowie Slicing- und Dicing-Operationen (Chaudhuri und Dayal, 1997)

Data Mining

Analyse großer Datenbestände, um Zusammenhänge, Muster und Regeln zu finden, die als Orientierungshilfe bei der Entscheidungsfindung und der Vorhersage künftiger Entwicklungen dienen können. Arten von Informationen, die durch Data Mining abgeleitet werden können:

Assoziationen

- Assoziationen sind Ausprägungen, die einem einzelnen Ereignis zugeordnet sind.
- Beispielsweise könnte eine Studie von Einkaufsmustern, die sogenannte Warenkorbanalyse, im Supermarkt zeigen, dass beim Kauf von Kartoffelchips in 65% aller Fälle auch Cola gekauft wird, während für den Fall einer speziellen Werbekampagne in 85% aller Fälle Cola gekauft wird.

Sequenzen

- In Sequenzen sind die Ereignisse über die Zeit verknüpft.
- Man könnte beispielsweise feststellen, dass beim Kauf eines Hauses in 65% aller Fälle innerhalb von zwei Wochen ein neuer Kühlschrank gekauft wird und in 45% aller Fälle innerhalb eines Monats ein Herd

Klassifizierung

- Die Klassifizierung erkennt Muster, die die Gruppe beschreiben, zu denen ein Artikel gehört, indem sie vorhandene Artikel untersucht, die bereits klassifiziert wurden, und eine Regelmenge ableitet.
- Die Klassifizierung kann helfen, etwa die Eigenschaften von Kunden zu erkennen, die wahrscheinlich wechseln wollen, und ein Modell bereitstellen, das hilft, Kampagnen durchzuführen, um solche Kunden zu halten.

Data Mining

Clustering

- Clustering arbeitet ähnlich wie die Klassifizierung, wenn noch keine Gruppen definiert wurden. Ein Data-Mining-Werkzeug erkennt verschiedene Gruppierungen innerhalb von Daten.
- Beispielsweise kann es Ähnlichkeitsgruppen für Bankkarten ermitteln oder die Kundendatensätze einer Datenbank in Kundengruppen segmentieren, die auf Umfragen und den persönlichen Ausgabeverhalten beruhen.

Prognose / Forecasting

- Die Prognose- oder Forecasting-Technik bedient sich statistischer Regressions- und Zeitreihenanalysen.
- Regressionsanalysen lassen sich heranziehen, um bei gegebenen (hypothetischen) Datenwerten, zukünftige Werte oder Ereignisse auf der Basis historischer Trends und Statistiken vorherzusagen (z.B. die Vorhersage des Absatzes von Fahrradzubehör auf Basis des Fahrradabsatzes im letzten Quartal).

Predictive Analytics

- Predictive Analytics verwendet Techniken des Data-Mining.
- Ziel ist, historische Daten und Annahmen über zukünftige Umweltzustände in einem Modellansatz zu integrieren, um den Ausgang von Ereignissen in der Zukunft vorherzusagen, wie etwa die Wahrscheinlichkeit, dass ein Kunde auf ein Angebot reagiert oder ein spezifisches Produkt kauft.

Daten-Wertschöpfungskette (Data Value Chain)

Laudon et al. S.304

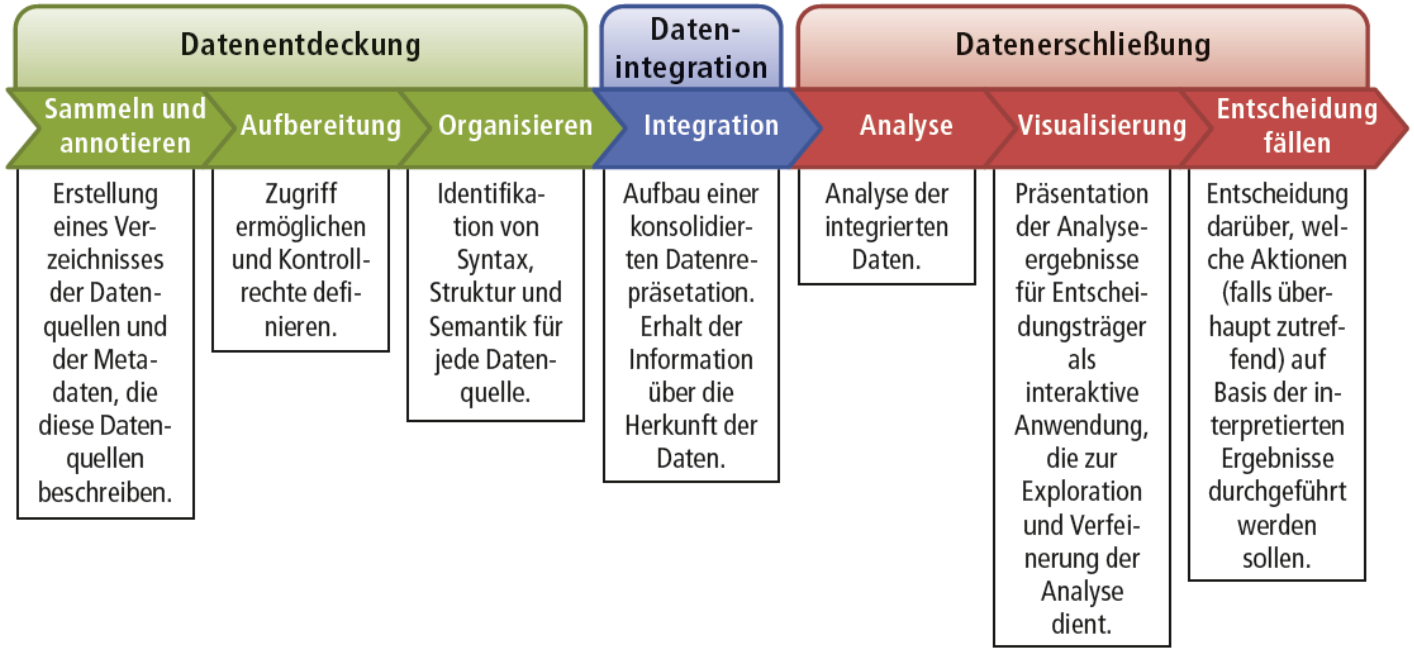


Abbildung 6.18: Die Data Value Chain (nach Miller und Mork, 2013, S. 58)

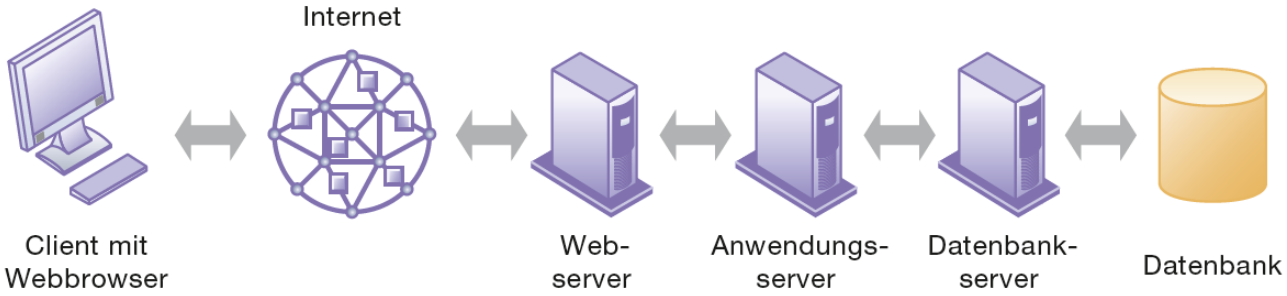
Die Data Value Chain (DVC) unterstützt die Big-Data-Prozesse von der Datensammlung über die Datenanalyse bis zur Entscheidungsfindung und ist dabei nicht an bestimmte Stakeholder und Technologien gebunden.

Die DVC ist dabei in drei Teilaufgaben Datenentdeckung (Data Discovery), Datenintegration und Datenerschließung (Data Exploitation) mit weiteren Unteraufgaben strukturiert.

Zugriff auf Datenbanken über das Web

Der Anwender greift über das Internet mit einem Webbrowser auf seinem Client-PC auf die Händler-Website zu.

Der Browser des Anwenders fordert Daten aus der Unternehmensdatenbank an und verwendet HTTP zur Kommunikation mit dem Webserver. Der Webserverdienst übergibt Datenanforderungen an Software, die die HTTP Anfrage in SQL übersetzt, die das DBMS der Datenbank verarbeiten kann. Das DBMS empfängt die SQL-Anforderungen und stellt die erforderlichen Daten bereit.



Laudon et al. S.307

Abbildung 6.20: Verknüpfung interner Datenbanken mit dem Web
Die Benutzer greifen mithilfe z. B. eines PCs und eines Webbrowsers über das Internet auf die interne Datenbank eines Unternehmens zu.

Der Zugriff auf die internen Datenbanken eines Unternehmens über das Internet ist mit zahlreichen Vorteilen verbunden:

- Verwendung von Webbrowsern viel einfacher als der Einsatz proprietärer Abfragetools
- Erfordert die Webschnittstelle nur wenige oder gar keine Anpassungen der internen Datenbank.
- Preisgünstiger, eine Webschnittstelle einem bewährten System hinzuzufügen
- Zugriff auf Unternehmensdatenbanken über das Web bietet neue Funktionen, Chancen und Geschäftsmodelle.

Das war‘s für heute

- Löhl/Lörcher/Sahm, 2005, Fachhochschule Heilbronn, Vortrag Historische Entwicklung von Datenbanken
- KEMPER, A.; EICKLER, A.: Datenbanksysteme: Eine Einführung, Oldenbourg: München, 10. Auflage (2015)
- ELMASRI, R.; NAVATHE, S. B.: Grundlagen von Datenbanksystemen: Bachelorausgabe Pearson Studium: München 2009
- Laudon, Kenneth C.; Laudon, Jane P.; Schoder, Detlef: Wirtschaftsinformatik, Eine Einführung (3. Auflage, 2015)